Universidad Politécnica de Chiapas
Ingeniería en Tecnologías de la Información e Innovación Digital (IT2iD)
Bases de Datos en la Nube · 2026

Medición de métricas en bases documentales

Contención de CPU y memoria en agregaciones JSON:
MongoDB frente a PostgreSQL JSONB

Objetivo

Medir latencia, rendimiento y huella de recursos al ejecutar agregaciones JSON anidadas bajo límites estrictos de CPU (CFS throttling) y memoria con Docker cgroups v2, comparando un motor documental con un motor relacional que almacena documentos en JSONB.

1. Preguntas sobre las métricas

M1 ¿Cómo cambian la latencia P95 y P99 de las agregaciones sobre documentos anidados cuando se limita de forma estricta la CPU y la memoria?

M2 ¿Qué motor usa de forma más eficiente los buffers de ordenamiento y agrupamiento antes de volcar a disco temporal o fallar por falta de memoria (OOM)?

M3 ¿Cuál es la huella de CPU y memoria por cada 1 000 documentos procesados en el motor documental frente al motor con JSONB?

2. Motores objetivo

Motor	Modelo de datos / versión	Indexación
MongoDB	Colección `orders` sin sharding; WiredTiger; latest-stable	Índice simple en `timestamp` y `order_id`
PostgreSQL	Tabla `orders (id UUID PRIMARY KEY, data JSONB)`; latest-stable	PK en `id`; B-Tree sobre `timestamp` extraído del JSONB

3. Perfiles de recursos (Docker / cgroups v2)

ID	Nombre	CPUs	Memoria	`mem_swappiness`
`PROFILE_A_BASELINE`	Sin contención (Baseline)	4,0	4096 m	0
`PROFILE_B_MEDIUM`	Contención media	2,0	2048 m	0
`PROFILE_C_SEVERE`	Contención severa (throttling activo)	1,0	1024 m	0

4. Especificación del dataset

- **Registros:** 500 000 · formato JSON · **3** niveles de anidamiento · promedio **3** ítems por registro.
- **Atributos:**

- `order_id` (UUID), `timestamp` (ISO-8601)
- `customer` (objeto: `id`, `tier`, `segment`, `geo[country, state, city, zip, coordinates]`)
- `items` (arreglo de objetos: `sku`, `category`, `brand`, `qty`, `price`, `tax_pct`, `discounts`)
- `payment` (objeto: `method`, `status`, `transaction_id`, `gateway_latency_ms`, `totals`)
- `metadata` (objeto: `channel`, `user_agent`, `session_id`, `flags`)

5. Cargas de trabajo (consultas)

5.1. Q1 — Unwind, Filter & Grouping (saturación de CPU)

Desanidar el arreglo de ítems, filtrar `price >50`, calcular subtotal (`qty * price`) y agrupar sumatoria y promedio por país y categoría.

MongoDB (pipeline).

```
[
  { "$unwind": "$items" },
  { "$match": { "items.price": { "$gt": 50 } } },
  {
    "$group": {
      "_id": {
        "country": "$customer.geo.country",
        "category": "$items.category"
      },
      "total_revenue": { "$sum": { "$multiply": ["$items.qty", "$items.price"] } },
      "avg_revenue": { "$avg": { "$multiply": ["$items.qty", "$items.price"] } },
      "count": { "$sum": 1 }
    }
  }
]
```

PostgreSQL.

```
SELECT data->'customer'->'geo'->>'country' AS country,
       item->>'category' AS category,
       SUM((item->>'qty')::numeric * (item->>'price')::numeric) AS total_revenue,
       AVG((item->>'qty')::numeric * (item->>'price')::numeric) AS avg_revenue,
       COUNT(*) AS count
FROM orders, jsonb_array_elements(data->'items') AS item
WHERE (item->>'price')::numeric > 50
GROUP BY 1, 2;
```

5.2. Q2 — Massive Sort & Top-K (estrés de buffer)

Filtrar órdenes completadas en un rango de fechas, ordenar descendente por `payment.final_total` y obtener el Top-1000 sin índices previos en el total.

Variantes de estrés de memoria.

- MongoDB: `allowDiskUse: false` / `allowDiskUse: true`
- PostgreSQL: `SET work_mem = '4MB'` / `SET work_mem = '64MB'`

MongoDB (pipeline).

```
[
  { "$match": {
      "payment.status": "completed",
      "timestamp": { "$gte": "2026-01-01T00:00:00Z" }
  } },
  { "$sort": { "payment.final_total": -1 } },
```

```
  { "$limit": 1000 },
  { "$project": {
      "order_id": 1, "customer.id": 1, "payment.final_total": 1
  } }
]
```

PostgreSQL.

```
SELECT data->>'order_id' AS order_id,
       data->'customer'->>'id' AS customer_id,
       (data->'payment'->>'final_total')::numeric AS final_total
FROM orders
WHERE data->'payment'->>'status' = 'completed'
  AND (data->>'timestamp')::timestamptz >= '2026-01-01 00:00:00Z'
ORDER BY (data->'payment'->>'final_total')::numeric DESC
LIMIT 1000;
```

6. Protocolo de ejecución

- **Concurrencia:** 1, 10, 50 clientes.
- **Repeticiones** por escenario: 3.
- **Ciclo de vida:**
  - Flush de caché: `sync; echo 3 >/proc/sys/vm/drop_caches`
  - Warmup: 60 s · medición: 300 s · cooldown: 60 s
- **Mediciones totales:** 36 celdas de la matriz (2 motores × 3 perfiles × 2 queries × 3 concurrencias); cada celda × 3 repeticiones.

7. Telemetría y KPIs

Stack.

- **cAdvisor:** métricas de contenedor (cgroups v2).
- **Node Exporter:** métricas de host (I/O, disco, swap).
- **Prometheus:** `scrape_interval: 1s`.

Indicadores.

KPI	Unidad	Tipo
`throughput_qps`	queries/s	Performance
`latency_p50_ms`	ms	Performance
`latency_p95_ms`	ms	Performance
`latency_p99_ms`	ms	Performance
`container_cpu_cfs_throttled_seconds_total`	s	OS / Contention
`container_memory_rss_bytes`	bytes	OS / Memory
`disk_spill_detected`	boolean	Engine / Internal
`oom_killed`	boolean	Stability

8. Entregables

8.1. Repositorio de código

- `docker-compose.yml` con perfiles de recursos parametrizados
- `synthetic_data_generator.py` (dataset 500k)
- `benchmark_runner` (scripts k6 o Python multiproceso)
- `queries/` (agregaciones MongoDB y SQL PostgreSQL)
- `run_benchmarks.sh` (automatización de la matriz de mediciones)

8.2. Esquema CSV de mediciones

```
timestamp_epoch, engine, profile, query_id, concurrency, run_number,
throughput_qps, latency_p50_ms, latency_p95_ms, latency_p99_ms,
cpu_throttled_seconds, max_rss_mb, disk_spill, status
```

8.3. Secciones del reporte de métricas

1. Especificaciones del host y del entorno Docker
2. Método de medición y verificación del baseline
3. Resultados consolidados (throughput, P95/P99, tiempo de throttling)
4. Análisis gráfico (P99 vs concurrencia, throttling vs QPS, curva RSS)
5. Planes de ejecución (`explain executionStats` frente a `EXPLAIN ANALYZE BUFFERS`)
6. Interpretación: límites de memoria, volcado a disco y throttling de cgroups
7. Recomendaciones técnicas para despliegues documentales en la nube